

---

## Tarification et détection d'anomalies sur les sinistres

*Approche hybride XGBoost, Autoencodeurs  
et Analyse Agentique*

---

**Auteur :** Antony MAIRLOT

**Jeu de données :** Kaggle – *Actuarial Loss Estimation* (54 000 polices)

**Enseignant :** Aurélien Couloumy

**Année universitaire :** 2025–2026

## Table des matières

|   |                                      |    |
|---|--------------------------------------|----|
| 1 | Introduction                         | 1  |
| 2 | Données et périmètre                 | 2  |
| 3 | Modélisation et architecture         | 5  |
| 4 | Résultats et analyses de sensibilité | 8  |
| 5 | Framework technique                  | 13 |
| 6 | Limites et perspectives              | 13 |
| 7 | Bibliographie                        | 15 |

## 1 Introduction

Ce projet combine apprentissage automatique, apprentissage profond et intelligence artificielle générative autour d'un cas d'usage central de l'assurance dommages corporels : la tarification et la surveillance qualité des sinistres accidents du travail (*workers compensation*). Il reprend deux des thématiques indicatives de la note de cadrage – la tarification par gradient boosting (sujet n°1) et le score de gravité (sujet n°6) – en les traitant conjointement au sein d'une architecture unique plutôt que de manière disjointe.

### 1.1 Problématique métier

Lorsqu'un sinistre accident du travail est déclaré, l'assureur ne dispose initialement que d'informations partielles et d'un premier montant provisionné (*InitialIncurredCalimsCost*). Le coût final réel du sinistre (*UltimateIncurredClaimCost*), qui intègre l'ensemble des indemnisations et frais jusqu'à la clôture du dossier, peut s'en écarter significativement : l'évolution médicale du blessé diffère parfois du pronostic initial, ou le dossier est mal caractérisé dès l'origine. Il en découle deux questions décisionnelles :

- **Tarification et provisionnement** : comment estimer, au plus tôt, le coût ultime probable d'un sinistre à partir des caractéristiques de la police, de l'assuré et de la description initiale des faits ?
- **Détection d'anomalies** : comment identifier, parmi des dizaines de milliers de dossiers, les sinistres dont le profil statistique est atypique (risque de sous-provisionnement, erreur de saisie, ou fraude potentielle) afin d'orienter la revue humaine vers les cas à plus forte valeur ajoutée ?

### 1.2 Valeur ajoutée pour le secteur assurantiel

Une estimation précoce et fiable du coût ultime améliore directement la qualité du provisionnement, en réduisant l'écart *IBNER* (*Incurred But Not Enough Reported*), et permet d'ajuster la tarification de contrats similaires. La détection non supervisée d'anomalies répond à un objectif distinct : elle ne cherche pas à prédire une valeur mais à repérer les dossiers dont la combinaison de variables s'écarte de la norme statistique du portefeuille, ce qui la rend complémentaire d'un modèle supervisé – ce dernier ne pouvant détecter que ce qu'il a explicitement appris à reconnaître. Enfin, la description libre du sinistre (*ClaimDescription*) constitue une donnée textuelle demeurée largement sous-exploitée dans l'approche traditionnelle ; les techniques de traitement du langage naturel (NLP) et d'IA générative permettent d'en extraire un signal quantitatif directement mobilisable par les modèles actuariels usuels.

### 1.3 Approche retenue et corrections méthodologiques

Une version antérieure de ce projet présentait une lacune méthodologique significative : l'absence de toute recherche d'hyperparamètres documentée pour le modèle de tarification. La version présentée ici corrige ce point et l'inscrit dans une architecture à trois flux complémentaires, détaillée en Section 3 :

| Flux                           | Technique                                                                                            | Rôle dans le pipeline                                                       |
|--------------------------------|------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| 1. ML supervisé                | XGBoost et recherche d'hyperparamètres (Optuna, <i>TPE Sampler</i> , comparé à <i>GridSearchCV</i> ) | Modèle de référence pour la prédiction de <i>UltimateIncurredClaimCost</i>  |
| 2. Deep Learning non supervisé | Autoencodeur (couches denses 64-32-16-32-64)                                                         | Détection d'anomalies sur variables tabulaires ; score réinjecté en feature |
| 3. NLP / IA générative         | <i>SentenceTransformer</i> (embeddings) et agent de score de gravité (heuristique / LLM)             | Exploitation de <i>ClaimDescription</i> ; feature de gravité ordinale       |

**Table 1** – Architecture à trois flux du pipeline de modélisation.

Une analyse par ablation (Section 4) mesure ensuite la contribution marginale des flux 2 et 3 par rapport au flux 1 seul, afin de déterminer si la complexité supplémentaire introduite par l'apprentissage profond et le NLP se justifie empiriquement.

## 2 Données et périmètre

### 2.1 Source et volumétrie

Les données proviennent de la compétition Kaggle *Actuarial Loss Estimation*<sup>1</sup> : 54 000 polices d'assurance accidents du travail (*workers compensation*), pour des sinistres survenus principalement entre 1988 et 2007. Aucune donnée n'ayant été fournie par l'enseignant, le téléchargement – création d'un compte Kaggle et acceptation des règles de la compétition – a constitué la première étape autonome du projet.

Il convient de le signaler explicitement : ce jeu de données est également celui mobilisé dans le support de cours « Data préparation » (TD2). Ce choix résulte d'un arbitrage assumé : partir d'un jeu de données déjà documenté a permis de concentrer l'effort disponible sur un traitement dépassant largement le périmètre illustratif du TD, lequel se limite à une imputation par le mode et une régression logistique de référence. Le présent projet développe à l'inverse une recherche d'hyperparamètres bayésienne, un audit croisé de l'importance des variables mettant au jour un biais du critère de gain de XGBoost (Section 4.6), un ajustement actuariel d'inflation et un agent LLM à appel d'outils (Sections 3.6 et 8.4 du notebook). L'autonomie du travail se situe ainsi dans la profondeur du traitement apporté à un jeu de données connu plutôt que dans la découverte d'une source inédite.

### 2.2 Variables et périmètre fonctionnel

| Type          | Variables                                                                          | Usage                                                                         |
|---------------|------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Cible         | UltimateIncurredClaimCost                                                          | Coût ultime du sinistre à prédire (régression)                                |
| Numériques    | Age, WeeklyWages, HoursWorkedPerWeek, DaysWorkedPerWeek, InitialIncurredCalimsCost | Variables tabulaires du flux ML (1)                                           |
| Catégorielles | Gender, MaritalStatus, DependentChildren, DependentsOther, PartTimeFullTime        | Encodées en indicatrices ( <i>one-hot</i> ) pour le flux ML (1)               |
| Dates         | DateTimeOfAccident, DateReported                                                   | Dérivation de variables temporelles (année, mois, jour, délai de déclaration) |
| Texte libre   | ClaimDescription (ex. « lifting tyre injury to right arm »)                        | Embeddings et score de gravité pour le flux NLP (3)                           |
| Identifiant   | ClaimNumber                                                                        | Clé technique, exclue de la modélisation                                      |

Table 2 – Variables du jeu de données et usage dans le pipeline.

### 2.3 Contrôle qualité et prétraitement

Le jeu de données ne contient aucun doublon. Une seule variable présente des valeurs manquantes, **MaritalStatus** (29 cas sur 54 000, soit 0,054 %), pour laquelle l'imputation par le mode a été délibérément écartée : en assurance, un champ déclaratif vide n'est presque jamais totalement aléatoire (*MCAR*) – il peut signaler une urgence médicale reléguant les formalités administratives au second plan, ou une situation déclarative atypique. Forcer ces observations vers la modalité majoritaire aurait effacé ce signal sans même l'examiner. Une catégorie **Missing** à part entière a donc été créée. Un test de Mann-Whitney (non paramétrique, mieux adapté qu'un test de Student à une cible aussi asymétrique) compare le coût moyen de ces 29 sinistres (5 326 \$, médiane 1 482 \$) à celui du reste du portefeuille (11 006 \$, médiane 3 372 \$) : l'écart n'atteint pas le seuil de significativité à 5 % ( $p = 0,08$ ), mais s'en approche suffisamment, sur un échantillon aussi restreint, pour justifier le maintien de la catégorie dédiée plutôt qu'un tranchage prématuré.

Les diagrammes en boîte révèlent par ailleurs une anomalie de saisie sur **HoursWorkedPerWeek**, avec des valeurs atteignant 640 heures – une valeur physiquement impossible sur une semaine de 168 heures au maximum. Plutôt que de s'en remettre à la robustesse supposée de XGBoost pour absorber ces valeurs, un traitement en deux temps est appliqué (détaillé en Section 3.2) : des règles métier de plausibilité, puis une winsorisation statistique des valeurs extrêmes résiduelles. L'effet réel de ce traitement sur la performance du modèle est mesuré empiriquement en Section 4.4, plutôt que simplement postulé.

### 2.4 Analyse exploratoire

Les corrélations linéaires entre variables numériques et la cible demeurent faibles (Figure 2) ; la plus élevée est celle du montant initialement provisionné (**InitialIncurredCalimsCost**,  $\rho = 0,39$ ). La cible étant fortement asymétrique (coefficient d'asymétrie de 37,6), s'en tenir au coefficient de Pearson serait méthodologiquement erroné : cette mesure suppose une relation linéaire et se trouve fortement distordue par les valeurs extrêmes. Elle est donc complétée par un coefficient de Spearman, calculé sur les rangs et par conséquent robuste à la non-linéarité monotone. L'écart entre les deux coefficients est précisément le plus marqué pour **InitialIncurredCalimsCost** (+0,49 point,  $\rho_{\text{Spearman}} = 0,88$ ), ce qui confirme que la relation réelle est substantiellement plus forte que ce que le seul coefficient de Pearson laissait supposer.

<sup>1</sup><https://www.kaggle.com/competitions/actuarial-loss-estimation/data>




Figure 1 – Distribution de *UltimateIncurredClaimCost* : brute (très asymétrique, coefficient d'asymétrie de 37,6) et après transformation *log1p* (à des fins de visualisation uniquement).




Figure 2 – Matrice de corrélation (Pearson, à gauche) et matrice de corrélation de Spearman sur les rangs (à droite). *InitialIncurredCalimsCost* est la variable numérique la plus corrélée à la cible dans les deux cas (0,39 et 0,88).

Les coefficients de Pearson et de Spearman demeurent l'un comme l'autre des mesures de relation monotone. Afin de capter des relations plus générales, l'information mutuelle et un *Predictive Power Score* (PPS) simplifié ont également été calculés – un arbre de décision peu profond, validé par validation croisée à 5 plis, comparé à une base de référence naïve par la médiane. Les deux mesures confirment sans ambiguïté qu'*InitialIncurredCalimsCost* domine largement les autres variables numériques (IM= 0,91, PPS= 0,22). Un test de facteur d'inflation de la variance (VIF) écarte par ailleurs tout problème de multicollinéarité (VIF < 2 pour l'ensemble des variables).





Figure 3 – Information mutuelle et Predictive Power Score (PPS) des variables numériques avec la cible.

#### 2.4.1 Analyse bivariée des variables catégorielles

Décrire les variables catégorielles indépendamment de leur lien avec le coût n'aurait pas suffi à justifier des choix de tarification. Les 5 variables catégorielles (*Gender*, *MaritalStatus*, *PartTimeFullTime*, *DependentChildren*, *DependentsOther*) ont donc été soumises à un test de Kruskal-Wallis – l'équivalent non paramétrique de l'analyse de variance, mieux adapté à une cible aussi éloignée de la loi normale – et les cinq variables ressortent significativement associées au coût ( $p < 0,05$ ). Plusieurs résultats méritent d'être relevés : les femmes, qui représentent 22,8 % du portefeuille, présentent un coût moyen supérieur de 23 % à celui des hommes (12 878 \$ contre 10 448 \$) ; les sinistres pour lesquels *DependentsOther* est renseigné (0,9 % des cas seulement) coûtent près de deux fois plus cher en moyenne (22 006 \$ contre 10 902 \$) ; et la modalité *Missing* de *MaritalStatus* affiche, en cohérence avec


la Section 2.3, le coût moyen le plus faible de l'ensemble des modalités.



**Figure 4** – Distribution du coût (échelle logarithmique) par modalité, pour chacune des 5 variables catégorielles. L'ensemble des différences est statistiquement significatif (Kruskal-Wallis,  $p < 0,05$ ).

#### 2.4.2 Analyse temporelle : tendance sur 17 ans et ajustement d'inflation

Le portefeuille couvre des sinistres survenus entre 1988 et 2005, déclarés jusqu'en 2007, soit 17 années d'historique. Comparer un sinistre de 1988 à un sinistre de 2005 en dollars nominaux n'est pas pertinent sur le plan actuariel, le coût moyen nominal croissant d'environ 8,9 % par an sur la période (Figure 5). Chaque sinistre est en conséquence corrigé par un ajustement d'inflation actuariel, fondé sur l'indice *CPI Medical Care* du *Bureau of Labor Statistics* (BLS). Les valeurs de cet indice ont été obtenues par l'intermédiaire d'un agrégateur tiers ([in2013dollars.com](https://in2013dollars.com)), ce qui constitue un proxy de travail commode mais imparfait : une version de production nécessiterait le requêtage direct des séries statistiques publiées par le BLS, garantissant traçabilité et actualisation continue de la source (limite reprise en Section 6). Une fois ramenée en dollars équivalents 2007, la tendance ne disparaît pas intégralement : la croissance résiduelle après correction reste de 4,0 % par an (Figure 6), ce qui indique que l'inflation médicale n'explique qu'environ la moitié de la hausse observée. Le solde pourrait tenir à une immaturité de développement des sinistres les plus récents – l'ultime n'étant pas encore atteint, question classique de provisionnement – ou à une évolution réelle de la sévérité des sinistres ; seule une analyse de développement dédiée, hors du périmètre de ce projet, permettrait de trancher. Une analyse de saisonnalité (Figure 5) ne fait apparaître, en tout état de cause, aucune tendance mensuelle marquée dans la fréquence des accidents.




**Figure 5** – Coût nominal moyen et médian par année de survenance (gauche) et fréquence des accidents par mois (droite, saisonnalité).

Les bigrammes les plus fréquents dans *ClaimDescription* (*lower back*, *back strain*, *foreign body*, *left/right hand*, entre autres) révèlent une structure sémantique nette, associant systématiquement un type de lésion à une partie du corps. Ce constat motive le flux NLP présenté en Section 3.6 : un simple encodage sac-de-mots aurait ignoré ces associations.

## 2.5 Restrictions et périmètre retenu

- La séparation entre apprentissage et test est réalisée par le projet lui-même (80 % / 20 %, graine aléatoire fixe) à partir du seul fichier `train.csv` fourni par Kaggle ; le fichier `test.csv` de la compétition, dépourvu de la variable cible, n'est pas utilisé pour l'évaluation.
- Aucune donnée externe supplémentaire (géospatiale, table de mortalité) n'est intégrée, hormis l'indice d'inflation *CPI Medical Care* utilisé pour la tendance actuarielle (Section 2.4).
- Les valeurs implausibles sont traitées explicitement (Section 3.2) plutôt que laissées à l'appréciation du modèle, et leur effet réel sur la performance est mesuré en Section 4.4.




**Figure 6** – Effet de l'ajustement d'inflation (indice CPI Medical Care) sur la tendance annuelle du coût moyen. La tendance résiduelle après ajustement (4,0 %/an) demeure non négligeable.

- L'ajustement d'inflation est réservé à une analyse de sensibilité dédiée (Section 4.7) ; le reste du pipeline (SHAP, audit de l'importance des variables, etc.) porte sur la cible nominale, afin d'éviter une duplication systématique des analyses sans changement notable de leurs conclusions.

## 3 Modélisation et architecture

### 3.1 Vue d'ensemble du pipeline

Avant d'entrer dans le détail de chaque flux, la Figure 7 situe l'ensemble du pipeline : des données brutes jusqu'aux sorties opérationnelles, en passant par le prétraitement commun et les trois flux de modélisation décrits dans les sous-sections suivantes.



**Figure 7** – Architecture d'ensemble : des données brutes aux trois flux (ML / DL / NLP-agentique), fusionnés dans le modèle XGBoost final, avec l'audit de l'importance des variables et les sorties opérationnelles (prédiction, anomalies, escalade).

### 3.2 Traitement des valeurs aberrantes

Préalablement à toute modélisation, les valeurs physiquement implausibles sont corrigées en deux temps. Premièrement, des règles métier : `HoursWorkedPerWeek` est plafonné à 98 heures par semaine (14 heures sur 7 jours, borne déjà large), `DaysWorkedPerWeek` à 7 jours, les valeurs hors bornes étant traitées comme manquantes puis imputées par la médiane (38 cas sur 54 000, soit 0,07 %). Deuxièmement, une winsorisation statistique (1<sup>er</sup> et 99<sup>e</sup> centiles) est appliquée à `WeeklyWages`, `HoursWorkedPerWeek` et `DaysWorkedPerWeek`, afin d'atténuer les valeurs extrêmes résiduelles mais plausibles. Une copie des données brutes est conservée pour quantifier l'effet réel de ce nettoyage en Section 4.4, plutôt que de supposer a priori que le modèle final s'en accommoderait.

### 3.3 Référence actuarielle classique : GLM Gamma à lien logarithmique

Préalablement au gradient boosting, une référence actuarielle standard est établie sur les mêmes variables explicatives que le modèle XGBoost de base : un modèle linéaire généralisé (GLM) de loi Gamma à lien logarithmique, famille de référence pour une sévérité strictement positive et asymétrique à droite (minimum observé de 122 \$, aucune valeur nulle ou négative sur `UltimateIncurredClaimCost`). Ce modèle s'écrit, pour chaque observation  $i$  :

$$Y_i \sim \Gamma(\mu_i, \phi), \quad \log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \quad (1)$$

où  $Y_i$  désigne le coût ultime du sinistre  $i$ ,  $\mu_i = \mathbb{E}[Y_i]$  son espérance conditionnelle,  $\phi$  le paramètre de dispersion de la loi Gamma, et  $\mathbf{x}_i$  le vecteur des variables explicatives. Le modèle atteint un RMSE de 27 579 et un MAE de 7 721 sur le jeu de test – une performance intermédiaire entre le XGBoost non optimisé (28 307) et le XGBoost optimisé (25 813).

Le recours à un triangle de développement (méthode Chain-Ladder ou Bornhuetter-Ferguson) n'a pas été retenu : ces méthodes s'appliquent à des données agrégées par année de survenance et période de développement, avec plusieurs valorisations successives d'une même cohorte de sinistres. Dans le présent jeu de données, chaque sinistre ne dispose que d'un unique montant ultime observé, sans date de valorisation intermédiaire : la structure en triangle nécessaire à ces méthodes n'existe donc pas. Le GLM Gamma demeure en revanche l'approche de référence pour la modélisation de la sévérité par sinistre en tarification IARD, antérieure et complémentaire au gradient boosting.

Chaque coefficient du GLM s'interprète directement comme un effet multiplicatif sur le coût attendu, sans recourir à une méthode d'explicabilité externe telle que SHAP – argument central en faveur de son usage dans un contexte réglementaire. En pratique, l'ajustement sur des variables d'échelles aussi disparates (indicatrices binaires, variables continues à échelles très différentes) impose une mise à l'échelle que XGBoost n'exige pas : une première tentative sans traitement préalable a strictement divergé (RMSE de l'ordre de  $10^{28}$ ), en raison de l'asymétrie extrême d'`InitialIncurredCalimsCost` (coefficient d'asymétrie de 26,85 sur les données brutes, cf. Section 2.4). Cette variable est en conséquence transformée par `log1p` avant standardisation des variables continues – pratique usuelle pour les variables monétaires à queue lourde, non un correctif ponctuel. Une fois l'ajustement stabilisé, l'effet le plus marqué demeure celui d'`InitialIncurredCalimsCost` (facteur multiplicatif de 1,71 pour une hausse d'un écart-type), les indicatrices catégorielles restant proches de l'unité (0,98 pour `Gender_M`, 0,97 pour `MaritalStatus_S`), sans effet démesuré.

Il importe de signaler, avant toute présentation de résultat, que les variables dérivées de `DateReported` (`ReportDelayDays`, jour de la semaine de déclaration, etc.) sont suspectes par construction : un outil conçu pour estimer un coût dès la première notification du sinistre ne devrait pas s'appuyer sur des variables dépendant de la date de déclaration elle-même. Cette hypothèse est vérifiée et confirmée en Section 4.6, mais elle est formulée dès ce stade, avant l'entraînement du moindre modèle, afin de ne pas laisser penser à une découverte fortuite.

### 3.4 Flux 1 – Machine learning supervisé (XGBoost et Optuna)

Le modèle de référence est un régresseur XGBoost, retenu pour sa robustesse aux valeurs aberrantes, sa capacité à capturer des interactions non linéaires – justifiée par la faiblesse des corrélations linéaires constatée en Section 2.4 – et sa bonne gestion des variables catégorielles encodées en indicatrices.

Contrairement à une itération antérieure du projet, l'hyperparamétrage est ici recherché systématiquement au moyen d'Optuna (échantillonneur *TPE Sampler*, optimisation bayésienne), sur un espace couvrant `learning_rate`, `max_depth`, `n_estimators`, `subsample`, `colsample_bytree` et `min_child_weight`, évalué par validation croisée à 5 plis sur le RMSE, sur 40 essais. Optuna a été préféré à un `GridSearchCV` exhaustif pour deux raisons : l'espace de recherche est continu, et une grille discrète le couvrirait imparfaitement ou à un coût combinatoire élevé ; l'optimisation bayésienne concentre en outre les essais dans les régions les plus prometteuses plutôt que d'explorer uniformément l'espace des paramètres. Un `GridSearchCV` restreint (9 combinaisons sur `max_depth` et `learning_rate`) est néanmoins exécuté à titre de comparaison en Section 4.

La note de cadrage recommandant explicitement de ne pas se limiter à un seul modèle, LightGBM est également optimisé (Optuna, 20 essais) et comparé à XGBoost en Section 4. L'estimation finale du RMSE est en outre accompagnée d'un intervalle de confiance obtenu par validation croisée répétée (5 plis  $\times$  5 répétitions, Section 4.2), plutôt que d'une valeur ponctuelle issue d'une seule séparation train/test.

Les hyperparamètres retenus par Optuna au terme des 40 essais sont : `n_estimators`= 300, `max_depth`= 3, `learning_rate`≈ 0,0103, `subsample`≈ 0,935, `colsample_bytree`≈ 0,875, `min_child_weight`= 5 (RMSE moyen en validation croisée : 28 692 ; RMSE sur le jeu de test isolé : 25 813, cf. Section 4 – l'écart entre ces deux valeurs est cohérent avec la variance mesurée en Section 4.2). Cette combinaison est cohérente avec la structure des données : un arbre peu profond, un taux d'apprentissage faible et un sous-échantillonnage marqué des lignes et des colonnes limitent le risque de surapprentissage sur une cible aussi asymétrique (coefficient d'asymétrie de 37,6, cf. Section 2.4), plutôt que de mémoriser les quelques sinistres extrêmes du jeu d'entraînement.

### 3.5 Flux 2 – Apprentissage profond non supervisé (autoencodeur)

Un autoencodeur à couches denses symétriques (64-32-16-32-64, activation ReLU, sortie linéaire) est entraîné à reconstruire les variables tabulaires standardisées, le `StandardScaler` étant ajusté exclusivement sur les données d'entraînement. L'entraînement utilise l'optimiseur Adam, une fonction de perte de type erreur quadratique moyenne (MSE), et un arrêt anticipé (*early stopping*) sur la perte de validation avec une patience de 5 époques. L'erreur de reconstruction par observation sert de score d'anomalie :

$$\text{MSE}_i = \frac{1}{p} \sum_{j=1}^p (x_{ij} - \hat{x}_{ij})^2 \quad (2)$$

où  $p$  désigne le nombre de variables en entrée et  $\hat{x}_{ij}$  la valeur reconstruite par le réseau. Les sinistres dont le score dépasse le 99<sup>e</sup> centile, calculé sur l'échantillon d'entraînement, sont considérés comme atypiques. Ce score et l'indicateur binaire qui en résulte sont ensuite réinjectés comme nouvelles variables explicatives dans le modèle XGBoost du flux 1.

Une limite méthodologique doit ici être signalée explicitement : la fonction de perte MSE traite de façon identique l'ensemble des variables en entrée, y compris les indicatrices binaires issues de l'encodage *one-hot* des variables catégorielles. Or une erreur quadratique sur une variable binaire ne possède pas la même signification statistique que sur une variable continue – un écart de reconstruction de 0,3 sur une indicatrice  $\{0, 1\}$  est difficile à interpréter en probabilité d'appartenance, alors que le même écart sur une variable continue standardisée conserve un sens métrique direct. Cette hétérogénéité de traitement réduit la finesse de détection de l'autoencodeur sur les attributs discrets, et constitue une limite assumée du modèle plutôt qu'un raffinement recherché ; une fonction de perte hybride (MSE pour les variables continues, entropie croisée binaire pour les indicatrices) constituerait un raffinement naturel pour une itération ultérieure.

Afin de ne pas conclure hâtivement à la supériorité de l'apprentissage profond sur cette tâche, l'autoencodeur est comparé à Isolation Forest – une méthode d'ensemble classique, avec un taux de contamination cible identique de 1 %, sur les mêmes variables. La comparaison (accord entre les deux méthodes, profils de coût associés) fait l'objet de la Section 4.5.




Figure 8 – Courbe d'apprentissage de l'autoencodeur (perte MSE de reconstruction, train contre validation).

### 3.6 Flux 3 – NLP et IA générative

Trois composantes exploitent le texte libre, sous une contrainte commune : demeurer applicables à l'ensemble des 54 000 sinistres sans clé API ni coût récurrent.

- Des embeddings denses obtenus via `SentenceTransformer('all-MiniLM-L6-v2')` (modèle *open-source* exécuté localement, 384 dimensions), réduits ensuite par analyse en composantes principales (PCA) à 10 composantes (45,2 % de variance expliquée cumulée). Ce choix de la PCA répond avant tout à un impératif de rapidité d'exécution et de sobriété en ressources de calcul, dans un contexte de projet académique sans infrastructure dédiée. Il convient toutefois de noter qu'une méthode de réduction de dimension non linéaire telle qu'UMAP (*Uniform Manifold Approximation and Projection*) aurait constitué un choix plus rigoureux sur le plan méthodologique, la PCA étant par construction limitée à la préservation de la variance selon des axes linéaires et susceptible de dégrader la topologie sémantique non linéaire propre aux espaces d'embeddings de phrases. `all-MiniLM-L6-v2` demeure en outre un modèle généraliste, entraîné sur un corpus web large et non sur un corpus médical ou assurantiel : un modèle adapté au domaine, tel que ClinicalBERT, capterait vraisemblablement plus finement le vocabulaire lésionnel spécifique de `ClaimDescription` (nature de la blessure,

partie du corps, gravité clinique implicite) que ne le fait un encodeur de phrases entraîné sur des données génériques.

- Une exploration non supervisée : partitionnement par K-means, avec un nombre de classes sélectionné par score de silhouette parmi  $\{3, 4, 5, 6, 8\}$ , comparé à HDBSCAN, puis une projection t-SNE pour visualiser la structure sémantique du corpus et son lien avec le coût. Cette exploration demeure qualitative ; sa principale limite quantifiée (68 % des descriptions non assignées par HDBSCAN) est reportée en Section 6.
- Un score de gravité, gradué de 1 (léger) à 3 (sévère), obtenu par trois méthodes de complexité croissante : une heuristique lexicale fondée sur des mots-clés ; une approche *zero-shot* par similarité d'embeddings, comparant chaque description – par similarité cosinus dans le même espace sémantique – à des phrases-ancres décrivant chaque niveau de gravité, retenue comme méthode de production car applicable aux 54 000 sinistres sans appel API ; et un agent LLM réel (API OpenAI, invite conforme à la note de cadrage : « En tant qu'expert médical, analyse cette description... »), démontré sur un échantillon de 20 sinistres et utilisé comme étalon pour valider l'approche *zero-shot* au moyen du coefficient kappa de Cohen.

Ce dernier point appelle une réserve de conformité, traitée dès à présent et non uniquement en Section 6 : **ClaimDescription** révèle par nature des informations de santé, catégorie particulière de données au sens de l'article 9 du Règlement général sur la protection des données (RGPD), dès lors qu'elle se rattache à un assuré identifiable via **ClaimNumber** dans le système d'information de l'assureur – quand bien même l'appel API ne transmettrait que le texte libre, sans identifiant direct. Il faut l'affirmer sans détour : telle qu'elle est configurée dans ce projet – API généraliste hébergée hors Union européenne, sans contrat de sous-traitance ni garanties documentées – cette architecture constituerait, si elle était portée en production en l'état, une violation du RGPD, et non un simple risque théorique à surveiller. La cible opérationnelle n'est donc pas un simple accord contractuel additionnel mais un changement d'architecture : un modèle de langage de petite taille (*Small Language Model*, SLM) déployé *on-premise* ou dans l'environnement souverain de l'assureur, ou à défaut une anonymisation stricte par un modèle de reconnaissance d'entités nommées (NER) en amont de tout appel externe, validée par un délégué à la protection des données (DPO). C'est pour cette raison, et non pour la seule maîtrise des coûts, que la démonstration demeure subordonnée à la définition d'une variable d'environnement absente par défaut et limitée à un échantillon très restreint.

Ces trois méthodes demeurent néanmoins des classifications : aucune ne prend de décision autonome. Un agent de triage distinct a en conséquence été développé (notebook, Section 8.4), disposant de deux outils réels : **get\_claim\_signals**, qu'il doit invoquer lui-même pour obtenir les scores d'anomalie (autoencodeur, Isolation Forest) et de gravité avant de se prononcer, et **flag\_for\_manual\_review**, qu'il déclenche de sa propre initiative – non systématiquement – lorsqu'il juge le dossier à risque. La démonstration porte sur les sinistres déjà identifiés comme atypiques (Section 4.5), dans la même logique de maîtrise du coût des appels réels qu'en Section 4.8. C'est cette composante, et non le score de gravité, qui répond véritablement au critère de « cadre agentique » attendu par le sujet.

Cette architecture à trois niveaux permet de démontrer un cadre agentique authentique tout en conservant un pipeline reproductible sur l'intégralité du jeu de données, sans coût récurrent – une montée en complexité volontaire par rapport à la simple heuristique lexicale, dont l'apport réel par rapport à l'approche *zero-shot* est quantifié par un coefficient kappa de Cohen de 0,257 (Section 6).

### 3.7 Architecture d'ensemble et enrichissement progressif

Les trois flux sont assemblés par enrichissement progressif des variables explicatives du modèle XGBoost, ce qui permet de mesurer la contribution marginale de chaque composante en Section 4 :

| Variante                  | Composition des variables                                              |
|---------------------------|------------------------------------------------------------------------|
| Base                      | Variables tabulaires encodées (police, assuré, dates) – 22 variables   |
| Base + Autoencodeur       | + score d'anomalie et indicateur <b>ae_is_anomaly</b> – 24 variables   |
| Base + Autoencodeur + NLP | + 10 composantes PCA des embeddings et score de gravité – 35 variables |

*Table 3 – Composition des variantes de features évaluées par ablation.*

Les trois variantes réutilisent les mêmes hyperparamètres XGBoost – ceux déterminés par Optuna sur la variante de base (Section 3.3) – afin d'isoler l'effet des variables ajoutées sans le confondre avec un effet de ré-optimisation des hyperparamètres.

## 4 Résultats et analyses de sensibilité


### 4.1 Performance supervisée et comparaison de modèles

Les métriques sont calculées sur un jeu de test de 10 800 sinistres (20 % du jeu de données), jamais observé ni pendant l'entraînement ni pendant la recherche d'hyperparamètres. Conformément à la recommandation du sujet d'aborder le problème sous plusieurs angles, LightGBM est ajouté à titre de comparaison, avec sa propre recherche Optuna. Les métriques de comparaison sont définies classiquement par :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

| Variante                                       | RMSE (test) | MAE (test) |
|------------------------------------------------|-------------|------------|
| GLM Gamma (référence actuarielle, Section 3.3) | 27 579      | 7 721      |
| XGBoost par défaut (sans optimisation)         | 28 307      | 9 437      |
| XGBoost + Optuna (variables de base)           | 25 813      | 7 673      |
| XGBoost + GridSearchCV (comparaison)           | 26 905      | 7 669      |
| LightGBM + Optuna (comparaison)                | 25 995      | 7 729      |
| Base + Autoencodeur                            | 25 764      | 7 673      |
| Base + Autoencodeur + NLP                      | 25 565      | 7 554      |

**Table 4** – RMSE et MAE (test) selon la variante du pipeline.



**Figure 9** – RMSE (test) selon la variante du pipeline. Le GLM Gamma se situe entre le XGBoost par défaut et le XGBoost optimisé ; le gain principal provient de la recherche d'hyperparamètres Optuna (−8,8 % par rapport au XGBoost par défaut) ; LightGBM est légèrement en retrait par rapport à XGBoost (+0,7 % de RMSE).

XGBoost et LightGBM obtiennent des performances comparables. Cette convergence constitue un résultat rassurant sur le plan méthodologique : elle indique que le signal capté ne dépend pas d'un choix d'implémentation arbitraire, ni de l'un ni de l'autre ne s'imposant nettement comme supérieur sur ce jeu de données. Le GLM Gamma, malgré sa simplicité et en l'absence de toute recherche d'hyperparamètres, demeure à moins de 7 % du XGBoost optimisé : une part substantielle du signal est ainsi capturée par une structure additive simple, le gradient boosting apportant principalement un gain sur les interactions non linéaires que le GLM ne peut représenter par construction.


Le choix de la RMSE comme critère d'optimisation et d'évaluation de XGBoost appelle ici une réserve actuarielle qu'il convient d'explicitier plutôt que de taire. Ce choix est assumé avant tout pour la comparabilité directe, en dollars, avec le GLM Gamma de référence (Section 3.3) et avec les résultats habituels de la littérature. Or minimiser une erreur quadratique revient à pondérer chaque écart par son carré, ce qui, sur une cible dont le coefficient d'asymétrie atteint 37,6 (Section 2.4), concentre l'essentiel du signal d'apprentissage sur la poursuite des quelques sinistres extrêmes plutôt que sur la masse des sinistres de sévérité usuelle : un optimum mathématique qui n'est pas nécessairement l'optimum actuariel recherché pour un portefeuille de tarification. Une mise en production viserait plutôt une fonction de perte adaptée à l'hétéroscédasticité et à l'asymétrie propres aux coûts de sinistres – l'objectif `reg:tweedie` de XGBoost, dans la continuité de la famille Gamma déjà retenue en Section 3.3, ou une perte de Pseudo-Huber, moins sensible aux valeurs extrêmes que l'erreur quadratique sans les ignorer complètement comme le ferait la seule MAE. La RMSE est donc conservée ici comme critère de comparabilité inter-modèles et avec l'existant, non comme recommandation de production.

#### 4.1.1 Sensibilité aux hyperparamètres

L'importance de chaque hyperparamètre sur le RMSE est estimée par une analyse fANOVA (`optuna.importance.get_param_importances`), qui décompose la variance du score observé sur les 40 essais entre les six hyperparamètres explorés :

| Hyperparamètre                | Importance (fANOVA) |
|-------------------------------|---------------------|
| <code>learning_rate</code>    | 58 %                |
| <code>min_child_weight</code> | 14 %                |
| <code>n_estimators</code>     | 10 %                |
| <code>max_depth</code>        | 8 %                 |
| <code>colsample_bytree</code> | 6 %                 |
| <code>subsample</code>        | 4 %                 |

**Table 5** – Importance fANOVA des hyperparamètres XGBoost sur le RMSE (40 essais Optuna).




**Figure 10** – À gauche, importance des hyperparamètres sur le RMSE (Optuna, analyse fANOVA sur les 40 essais). À droite, convergence de la recherche : RMSE en validation croisée à chaque essai (TPE Sampler). La recherche bayésienne se concentre progressivement dans une région basse du RMSE, avec quelques essais d'exploration ponctuels même en fin de recherche (essai 29), comportement attendu du TPE Sampler, qui continue d'explorer l'espace des paramètres plutôt que de se limiter à l'exploitation du meilleur point courant.

Le `learning_rate` concentre à lui seul 58 % de l'influence sur le RMSE, loin devant `min_child_weight` (14 %) et `n_estimators` (10 %) ; `max_depth`, `colsample_bytree` et `subsample` se partagent le solde. Le taux d'apprentissage constitue ainsi le levier à ajuster en priorité, avant la profondeur des arbres ou le nombre d'estimateurs – résultat cohérent avec la valeur finalement retenue (`learning_rate`  $\approx 0,01$ , en limite basse de l'intervalle de recherche  $[0,01 ; 0,3]$ ).

## 4.2 Robustesse de l'estimation : validation croisée répétée

Une unique séparation train/test ne fournit qu'une estimation ponctuelle du RMSE, sensible à l'aléa du tirage. Une validation croisée répétée (5 plis  $\times$  5 répétitions, 25 estimations) sur le XGBoost optimisé conduit à un RMSE moyen de 28 485 avec un écart-type de 10 345, soit 36 % de la moyenne – une variabilité considérable, vraisemblablement imputable à la présence ou à l'absence, selon le pli tiré, des sinistres extrêmes (jusqu'à 4 millions de dollars, coefficient d'asymétrie de 37,6). La valeur obtenue sur la séparation unique (25 813, Section 4.1) se situe ainsi à moins d'un écart-type sous cette moyenne.



**Figure 11** – Distribution du RMSE sur 25 estimations (validation croisée répétée 5 $\times$ 5). La distribution asymétrique, avec une queue de plis à RMSE élevé, reflète le poids des sinistres extrêmes.

Cette observation a une conséquence directe pour la suite de l'analyse : les écarts inférieurs à 1 % entre variantes de variables, présentés en Section 4.3, sont potentiellement du même ordre de grandeur que ce bruit d'échantillonnage. Ils doivent en conséquence être interprétés comme des tendances indicatives, et non comme des différences solidement établies sur la seule base d'une séparation unique.

## 4.3 Contribution marginale de l'autoencodeur et du NLP

Dans cette expérience, l'ajout du score d'anomalie améliore le RMSE de façon marginale (25 813  $\rightarrow$  25 764, soit +0,19 %), et l'ajout complémentaire des variables NLP porte le gain cumulé à +0,96 % (25 813  $\rightarrow$  25 565). Ces gains demeurent modestes et, compte tenu de la variabilité mise en évidence en Section 4.2, un gain inférieur à 1 % ne se distingue pas clairement du bruit d'échantillonnage. De manière générale, l'autoencodeur et le module NLP produisent donc un gain de RMSE positif mais statistiquement fragile, ce qui ne remet pas en cause leur intérêt opérationnel propre (Section 4.5) mais relativise leur utilité pour la seule prédiction du coût.

Ce constat appelle une décision de conception, et non une simple observation : le modèle de tarification retenu pour la production n'intégrerait pas ces deux composantes comme variables de coût, le gain ne justifiant pas le coût de maintenance associé pour une amélioration non distinguable de l'aléa d'échantillonnage. Cela ne rend pas ces composantes inutiles pour autant – l'autoencodeur et Isolation Forest conservent leur valeur pour la


détection d'anomalies (Section 4.5), et l'approche *zero-shot* NLP demeure utile à l'agent de triage (Section 3.6). L'architecture de production séparerait ainsi deux systèmes distincts : un modèle de tarification (XGBoost seul) et un système de triage indépendant, plutôt que de les fusionner au seul motif qu'ils partagent le même jeu de données source.

#### 4.4 Qualité des données : effet mesurable du nettoyage

Le nettoyage des valeurs implausibles (Section 3.2) contribue-t-il réellement à la performance, ou uniquement à la qualité intrinsèque des données ? Le modèle de base, réentraîné sur les données brutes, produit un RMSE de 25 823 contre 25 813 sur les données nettoyées – un gain de 0,04 %, écart quasi nul et statistiquement non significatif au regard de la Section 4.2. Ce résultat confirme empiriquement, et non par simple supposition, que XGBoost demeure robuste face aux quelques dizaines de valeurs aberrantes présentes dans ce jeu de données précis. Le nettoyage demeure néanmoins justifié pour la qualité de l'analyse exploratoire, pour l'autoencodeur – structurellement plus sensible aux valeurs aberrantes qu'un modèle à base d'arbres – et pour la communication des résultats auprès d'interlocuteurs non spécialistes, quand bien même son effet sur le seul RMSE serait nul.

#### 4.5 Détection d'anomalies : autoencodeur contre Isolation Forest

L'accord entre l'autoencodeur et Isolation Forest (contamination cible identique de 1 %) est faible : indice de Jaccard de 0,122 seulement, 94 sinistres signalés conjointement par les deux méthodes sur 770 signalés par l'une ou l'autre. Les coûts moyens divergent nettement selon le groupe (Figure 12) : 45 964 \$ pour les sinistres signalés par les deux méthodes, contre 10 713 \$ pour ceux qui ne le sont par aucune. Prises isolément, les deux méthodes demeurent proches (25 315 \$ pour l'autoencodeur seul, 23 800 \$ pour Isolation Forest seul), sans qu'aucune ne domine clairement l'autre – ce qui relativise l'apport spécifique de l'apprentissage profond sur cette tâche par rapport à une méthode plus simple, plus rapide à entraîner et dépourvue d'hyperparamètre d'architecture à régler.



**Figure 12** – Coût moyen du sinistre selon l'accord entre l'autoencodeur et Isolation Forest (jeu d'entraînement). Le consensus des deux méthodes identifie les sinistres les plus coûteux.

##### 4.5.1 Sensibilité du seuil d'anomalie


Le choix du 99<sup>e</sup> centile comme seuil d'anomalie représente un compromis entre sensibilité et volume de faux positifs à traiter manuellement. En faisant varier ce seuil de 90 à 99,9 %, le nombre d'anomalies détectées sur le jeu de test passe de 1 090 à seulement 17, de façon quasi monotone décroissante. Le 99<sup>e</sup> centile (112 anomalies sur 10 800 sinistres de test) fournit un volume compatible avec une revue humaine ciblée, tout en demeurant suffisamment sélectif pour préserver la valeur informative du signal.

#### 4.6 Audit de l'importance des variables et biais du critère de gain (CART)

Sur une itération antérieure de ce projet, l'importance native de XGBoost (fondée sur le critère de « gain », c'est-à-dire la réduction de fonction de perte imputée à une variable lors des séparations de l'arbre) plaçait `DateReportedDayOfWeek` et `ReportDelayDays` – le délai entre l'accident et sa déclaration – très largement devant `InitialIncurredCalimsCost`, pourtant la variable la plus corrélée à la cible (Section 2.4). Il convient de nommer précisément ce phénomène : il ne s'agit pas, au sens strict, d'une fuite de données (*data leakage*), puisque ces deux variables sont authentiquement disponibles dès le premier jour, au moment de la déclaration du sinistre, et que leur usage n'anticipe aucune information future. Le problème relève d'une autre catégorie, bien documentée dans la littérature sur les arbres CART : un biais mécanique du critère de « gain », qui favorise à tort les variables continues ou à cardinalité élevée – offrant davantage de points de coupure candidats – indépendamment de leur pouvoir prédictif réel. Trois méthodes indépendantes ont été mobilisées afin de confirmer cette hypothèse plutôt que de s'y fier sur la seule base d'une lecture de la littérature.

- **SHAP** (`TreeExplainer`, Figure 13) : l'impact d'`InitialIncurredCalimsCost` sur la prédiction dépasse très largement celui de toute autre variable, tandis que `ReportDelayDays` et `DateReportedDayOfWeek` présentent un impact quasi nul et dépourvu de structure claire.

- **Importance par permutation**, mesurée sur le jeu de test et donc non biaisée par l'entraînement : `InitialIncurredCalimsCost` domine avec une valeur de 7143, très loin devant `ReportDelayDays` (20,5, avec un écart-type de 72,8 – l'écart-type dépassant la moyenne, ce signal relève davantage du bruit que de l'information) ; `DateTimeOfAccidentDayOfWeek` est quasi nul (0,18) et `MaritalStatus_Missing` strictement nul (0,0).
- **Ablation dédiée** : le retrait complet des variables dérivées de la date de déclaration améliore même légèrement le RMSE (25 813  $\rightarrow$  25 597, soit  $-0,84\%$  – une amélioration, non une dégradation).



**Figure 13** – À gauche, diagramme récapitulatif SHAP du modèle XGBoost optimisé (échantillon de test,  $n = 2000$ ) : `InitialIncurredCalimsCost` domine très largement l'impact sur la prédiction. À droite, importance des variables après retrait des variables de déclaration : la hiérarchie redevient cohérente avec l'intuition métier.

Ces trois méthodes convergent et confirment l'hypothèse posée en ouverture de section : il est en conséquence recommandé de retirer `ReportDelayDays` et `DateReportedDayOfWeek` du modèle de production, faute de valeur prédictive mesurable et au prix d'une complexité d'interprétation non justifiée. Cet exemple illustre pourquoi l'importance native d'un modèle à base d'arbres ne devrait jamais être interprétée isolément, sans être recoupée avec une seconde méthode (permutation, SHAP) et, autant que possible, un avis métier.

Il convient toutefois d'en circonscrire précisément la portée : cet audit demeure ciblé sur les variables directement dérivées du délai de déclaration, et sur un seul mécanisme, le biais du critère de gain. Une industrialisation du modèle exigerait d'étendre le même protocole – permutation, SHAP et ablation croisées – aux autres variables susceptibles de porter, cette fois au sens strict du terme, une fuite indirecte, temporelle ou non, à commencer par des variables telles que `Age`, dont la relation avec le processus de déclaration n'a pas été spécifiquement examinée dans le présent travail.

#### 4.7 Sensibilité : modélisation en dollars nominaux ou en dollars constants

Le modèle apprend-il plus efficacement à partir de dollars réels, la tendance d'inflation étant retirée au préalable (Section 2.4), ou à partir de dollars nominaux bruts ? Un second modèle XGBoost, aux hyperparamètres identiques, est entraîné sur la cible ajustée en dollars 2007, puis ses prédictions sont reconverties en dollars nominaux afin de comparer les RMSE sur une base homogène. Le RMSE obtenu est de 25 813 pour la cible nominale contre 25 598 pour la cible ajustée puis reconvertie, soit un gain de  $+0,83\%$  – supérieur au gain apporté par l'autoencodeur seul (Section 4.3) et du même ordre que celui du flux NLP complet. Retirer l'inflation en amont semble ainsi faciliter la capture, par le modèle, du signal structurel résiduel, même si ce gain demeure, comme les précédents, dans la marge de bruit identifiée en Section 4.2.

#### 4.8 Agent de triage à appel d'outils : coût et latence à l'échelle

L'agent de triage (Section 3.6, notebook Section 8.4) est démontré sur les sinistres déjà identifiés comme atypiques ( $n = 770$ , Section 4.5) plutôt que sur un tirage aléatoire, choix à la fois plus économique et plus pertinent sur le plan métier. Une estimation du coût de passage à l'échelle – indépendante de toute exécution réelle, notebook Section 8.5 – s'appuie sur la longueur moyenne effectivement mesurée des descriptions et sur les tarifs publics de gpt-4o-mini :

| Périmètre                       | Nb. sinistres | Coût estimé    | Latence séquentielle estimée |
|---------------------------------|---------------|----------------|------------------------------|
| Sinistres déjà anormaux (AE/IF) | 770           | $< 1 \$$       | $\approx 20$ min             |
| Portefeuille complet            | 54 000        | $\approx 3 \$$ | $\approx 24$ h (séquentiel)  |

**Table 6** – Estimation du coût et de la latence de l'agent de triage selon le périmètre d'application.

Ces ordres de grandeur – les tarifs devant être revérifiés avant tout usage réel – confortent la stratégie retenue en production : réserver l'agent réel aux cas déjà présélectionnés par les méthodes non supervisées. La latence pourrait au demeurant être réduite substantiellement par une parallélisation des appels.

## 5 Framework technique

### 5.1 Environnement technologique

Le Tableau 7 synthétise les choix technologiques retenus pour chaque composante du pipeline, ainsi que leur justification.

| Composant                     | Choix                                                                                                                                | Justification                                                                                                                      |
|-------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| Langage                       | Python 3.11                                                                                                                          | Compatibilité maximale avec l'écosystème ML/DL à la date du projet                                                                 |
| ML supervisé                  | XGBoost 3.x, LightGBM 4.x, Optuna 4.x                                                                                                | Gradient boosting (deux implémentations comparées) et recherche d'hyperparamètres bayésienne                                       |
| Explicabilité et statistiques | SHAP, scikit-learn (importance par permutation, information mutuelle), statsmodels (VIF), scipy.stats (Mann-Whitney, Kruskal-Wallis) | Audit de l'importance des variables et des biais de sélection, tests d'hypothèse non paramétriques adaptés à une cible asymétrique |
| Détection d'anomalies         | Isolation Forest (scikit-learn)                                                                                                      | Comparaison classique de l'autoencodeur, sans apprentissage profond                                                                |
| Apprentissage profond         | TensorFlow / Keras 3.x                                                                                                               | Autoencodeur dense, API haut niveau, calcul CPU suffisant pour ce volume                                                           |
| NLP                           | sentence-transformers (all-MiniLM-L6-v2), HDBSCAN                                                                                    | Embeddings et clustering, exécution locale, aucune clé API requise                                                                 |
| IA générative (optionnelle)   | API OpenAI (gpt-4o-mini)                                                                                                             | Démonstration de l'agent de score sur échantillon réduit, étalon de l'approche <i>zero-shot</i>                                    |
| Environnement                 | uv (gestionnaire Python isolé) et <code>venv</code>                                                                                  | Isolation stricte, absence de conflit de version Python                                                                            |
| Notebook                      | Jupyter (noyau dédié)                                                                                                                | Livrable technique exécuté et documenté                                                                                            |
| Gestion de versions           | Git (dépôt GitHub public)                                                                                                            | Traçabilité du code, exclusion des données brutes ( <code>.gitignore</code> )                                                      |

**Table 7** – Environnement technologique du projet.

### 5.2 Reproductibilité

L'environnement se reconstruit intégralement au moyen d'une unique commande, via le script `setup_env.ps1` fourni dans le dépôt : installation isolée de Python 3.11, indépendante de tout interpréteur système, création d'un environnement virtuel `.venv`, installation des dépendances figées (`requirements.txt`) et enregistrement d'un noyau Jupyter dédié. Aucune donnée brute n'est versionnée – `train.csv` doit être téléchargé séparément depuis Kaggle, conformément aux règles de la compétition – et aucune clé API n'est stockée dans le code source : la démonstration de l'agent LLM réel ne se déclenche que si la variable d'environnement `OPENAI_API_KEY` est définie, ce qui n'est pas le cas par défaut.

Ce point a fait l'objet d'une vérification empirique et non d'une simple supposition : deux exécutions complètes et indépendantes du notebook produisaient initialement des résultats d'autoencodeur légèrement différents d'une exécution à l'autre (seuil d'anomalie, indice de Jaccard, coûts par groupe de la Section 4.5), la fonction `np.random.seed` seule ne couvrant pas le moteur de calcul TensorFlow. Après l'ajout de `keras.utils.set_random_seed` et de `tf.config.experimental.enable_op_determinism()`, deux exécutions indépendantes ont produit des sorties strictement identiques, vérifiées valeur par valeur et non simplement annoncées.

### 5.3 Scalabilité et optimisation

- XGBoost et la recherche Optuna exploitent la parallélisation multi-cœurs (`n_jobs=-1`) afin de réduire le temps de recherche d'hyperparamètres.
- L'autoencodeur bénéficie d'un arrêt anticipé, qui évite de prolonger le calcul au-delà du point de convergence – l'arrêt survient autour de la 75<sup>e</sup> époque sur un budget de 100.
- Les embeddings de texte sont calculés une seule fois, par lots de 128 descriptions, puis réutilisés pour l'ensemble des variantes de modèle, sans recalcul redondant.

## 6 Limites et perspectives

### 6.1 Limites techniques identifiées

Le Tableau 8 synthétise, pour chaque limite technique identifiée au fil du rapport, sa description précise et la piste d'atténuation envisagée.

| Limite                                        | Description                                                                                                                                                                                                                                                                                                                                                                                                                                          | Piste d'atténuation                                                                                                                                                                                                           |
|-----------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Coût et latence de l'API (LLM)                | Agent réel démontré sur échantillon ciblé, non sur l'intégralité du portefeuille. L'approche <i>zero-shot</i> couvre les 54 000 sinistres sans API ( $\kappa=0,257$ contre l'heuristique).                                                                                                                                                                                                                                                           | Réserver l'agent réel aux sinistres déjà signalés anormaux (Section 4.8).                                                                                                                                                     |
| Variabilité de l'estimation                   | La validation croisée répétée (Section 4.2) révèle un écart-type du RMSE élevé relativement à sa moyenne. Les gains de quelques pourcents entre variantes (Section 4.3) demeurent statistiquement incertains.                                                                                                                                                                                                                                        | Systématiser la communication d'un intervalle de confiance, non d'une valeur ponctuelle, pour toute comparaison future.                                                                                                       |
| Interprétabilité – couverture partielle       | L'audit de l'importance des variables (Section 4.6) résout le cas <code>ReportDelayDays</code> (biais du critère de gain, non une fuite véritable) mais n'a pas été appliqué systématiquement à l'ensemble des variables potentiellement suspectes de fuite réelle, telles que <code>Age</code> .                                                                                                                                                    | Étendre le protocole (permutation, ablation, SHAP) à l'ensemble des variables avant tout déploiement en production.                                                                                                           |
| Qualité des données – couverture partielle    | Le nettoyage (Section 3.2) est sans effet mesurable sur XGBoost (+0,04 %), sans garantie équivalente pour l'autoencodeur (non réévalué sur données brutes).                                                                                                                                                                                                                                                                                          | Réévaluer l'autoencodeur sur données brutes contre données nettoyées.                                                                                                                                                         |
| Inflation – indice approximatif               | L'indice CPI Medical Care provient d'un agrégateur tiers utilisé comme proxy de travail, non directement du BLS. La croissance résiduelle (4,0 %/an) n'est pas diagnostiquée en détail.                                                                                                                                                                                                                                                              | Requêter directement les séries du BLS ; analyser la croissance résiduelle par une méthode de développement des sinistres.                                                                                                    |
| Modélisation cross-sectional vs longitudinale | Le coût ultime est prédit à un instant donné, sur 17 années d'historique (Section 2.4), sans variable de maturité ( <i>development lag</i> ) : les sinistres les plus récents, dont le développement n'est pas encore stabilisé, sont mécaniquement sous-représentés dans leur coût final observé – une explication plausible, non tranchée, de la croissance résiduelle relevée en Section 2.4.                                                     | Coupler XGBoost à un modèle de développement stochastique (Chain-Ladder <i>machine learning</i> ou réseau récurrent de type LSTM sur les paiements successifs), ou introduire une variable explicite de maturité du sinistre. |
| Fragilité des méthodes non supervisées        | Autoencodeur et Isolation Forest : indice de Jaccard de 0,122 (Section 4.5). HDBSCAN : 68 % des descriptions non assignées à un groupe. Les deux résultats dépendent fortement de la méthode et des paramètres retenus.                                                                                                                                                                                                                              | Communiquer les scores séparément, prioriser le consensus entre méthodes ; tester une grille de paramètres pour HDBSCAN.                                                                                                      |
| Conformité RGPD (détail Section 3.6)          | <code>ClaimDescription</code> révèle des données de santé rattachables à un assuré identifiable ; tel que configuré (API généraliste hors UE, sans DPA), l'agent LLM réel constituerait une violation du RGPD s'il était porté en production, non un simple risque théorique.                                                                                                                                                                        | Migrer vers un SLM ( <i>Small Language Model</i> ) déployé <i>on-premise</i> , ou une anonymisation NER stricte en amont, validée par un DPO.                                                                                 |
| Biais algorithmique                           | <code>Gender</code> et <code>MaritalStatus</code> , significativement associées au coût (Section 2.4), sont utilisées comme variables prédictives. Plusieurs juridictions (ex. Union européenne, arrêt <i>Test-Achats</i> ) interdisent l'usage du genre en tarification assurance – une contrainte qui ne s'applique pas à ce jeu de données américain mais qui devrait être vérifiée avant tout déploiement dans un cadre réglementaire différent. | Tester la discrimination indirecte (proxy) portée par ces variables et par leurs corrélats avant tout déploiement hors du périmètre académique.                                                                               |
| Sécurité (agent LLM)                          | L'agent à appel d'outils (Section 3.6) traite du texte libre non filtré ; le risque d'injection de prompt (instructions dissimulées dans <code>ClaimDescription</code> visant à manipuler l'appel d'outils) n'a pas été testé.                                                                                                                                                                                                                       | Ajouter une validation/assainissement des entrées et des tests d'injection de prompt avant tout déploiement réel.                                                                                                             |

Table 8 – Synthèse des limites techniques identifiées et pistes d'atténuation associées.

## 6.2 Perspectives d'amélioration

- Faire valider par un expert sinistres senior le retrait de `ReportDelayDays` et `DateReportedDayOfWeek`.
- Étendre l'agent LLM réel à un échantillon plus large de sinistres anormaux, et l'audit de qualité des données à l'ensemble des variables numériques, autoencodeur inclus.
- Explorer un autoencodeur variationnel (VAE) et sa propre recherche d'hyperparamètres dédiée.
- Explorer UMAP comme alternative à la PCA pour la réduction de dimension des embeddings, afin de mieux préserver la topologie sémantique non linéaire du corpus (Section 3.6).
- Affiner les phrases-ancres de l'approche *zero-shot*, actuellement concentrées sur le niveau de gravité intermédiaire.
- Requêter directement l'indice CPI Medical Care auprès du Bureau of Labor Statistics et approfondir l'analyse de la croissance résiduelle par une méthode de développement des sinistres.
- Coupler la prédiction cross-sectional actuelle à un modèle de développement des sinistres (Chain-Ladder *machine learning* ou LSTM) afin de corriger le biais de maturité identifié en Section 6.
- Remplacer le modèle d'embeddings généraliste `all-MiniLM-L6-v2` par un modèle adapté au domaine médical/assurantiel (ex. ClinicalBERT) pour mieux capter le vocabulaire lésionnel de `ClaimDescription`.

### 6.3 Note de transparence méthodologique

Une partie de la structuration, de la relecture orthographique et du code de génération de ce rapport et de la présentation associée (mise en forme, corrections linguistiques, scripts de génération de documents) a été réalisée avec l'assistance d'un outil d'intelligence artificielle générative, sous la supervision et la validation de l'auteur. Les analyses, choix méthodologiques, résultats numériques et interprétations demeurent intégralement ceux de l'auteur, vérifiés par exécution effective du notebook (Section 5). Cette mention est faite conformément à la note de cadrage, laquelle sanctionne l'usage non déclaré d'outils d'intelligence artificielle générative, et non leur usage en tant que tel.

## 7 Bibliographie

### Jeu de données et indices externes

- Kaggle. *Actuarial Loss Estimation* [jeu de données de compétition]. <https://www.kaggle.com/competitions/actuarial-loss-estimation/data>
- U.S. Bureau of Labor Statistics. *Consumer Price Index – Medical Care*. Valeurs annuelles 1988–2007 compilées via [in2013dollars.com/medical-care/price-inflation](https://in2013dollars.com/medical-care/price-inflation) (agrégateur tiers fondé sur la série BLS CUUR0000SAM ; limite de source documentée en Section 6).

### Références académiques et techniques

- Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. ACM SIGKDD.
- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). *Optuna: A Next-generation Hyperparameter Optimization Framework*. ACM SIGKDD.
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2<sup>e</sup> éd.). Chapman & Hall. (référence du GLM Gamma, Section 3.3)
- Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. EMNLP-IJCNLP.
- Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). *MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers*. NeurIPS. (modèle all-MiniLM-L6-v2 utilisé pour les embeddings)
- Sakurada, M., & Yairi, T. (2014). *Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction*. MLSDA Workshop.
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). *Isolation Forest*. IEEE ICDM.
- Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions* (SHAP). NeurIPS 30.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. NeurIPS 30.
- Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates* (HDBSCAN). PAKDD.
- McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv:1802.03426.
- Wetschoreck, F., Krael, T., & Krishnamurthy, S. (2020). *8 Reasons Why Predictive Power Score is a Better Alternative to Correlation*. 8080labs (implémentation simplifiée développée pour ce projet, cf. Section 2.4).
- Kruskal, W. H., & Wallis, W. A. (1952). *Use of Ranks in One-Criterion Variance Analysis*. Journal of the American Statistical Association.

### Documentation technique

XGBoost ([xgboost.readthedocs.io](https://xgboost.readthedocs.io)) – LightGBM ([lightgbm.readthedocs.io](https://lightgbm.readthedocs.io)) – Optuna ([optuna.readthedocs.io](https://optuna.readthedocs.io)) – SHAP ([shap.readthedocs.io](https://shap.readthedocs.io)) – Sentence-Transformers ([www.sbert.net](https://www.sbert.net)) – TensorFlow/Keras ([tensorflow.org/guide/keras](https://tensorflow.org/guide/keras)) – scikit-learn, **GammaRegressor** ([scikit-learn.org/stable](https://scikit-learn.org/stable)) – statsmodels, VIF ([statsmodels.org/stable](https://statsmodels.org/stable)).

### Support de cours

- Couloumy, A. *IA & Assurance – Data préparation, Introduction to Deep Learning (parties 1 à 3), Non-life pricing with ML, Natural Language Processing in Insurance*. Supports de cours, CNAM, Master 2 Actuariat, 2025.